

Персональный ИИ

Skoltech

Skoltech
Applied AI

Applied Artificial
Intelligence Center

Выводы

- **Разработана архитектура** графовой памяти для LLM, позволяющая автоматически строить граф по знаниям, прошедшим через модель, а также быстро и качественно производить поиск релевантной информации по запросу.
- **Сравнение этой архитектуры с RAG** показало превосходство графовой памяти над классической технологией.
- **Сформулированы возможные улучшения** предложенной графовой архитектуры, реализация которых позволит повысить точность извлечения информации из графа.
- **Датасет DiaASQ**, содержащий диалоги пользователей форума, **был расширен** дополнительными высказываниями, именами спикеров, временем диалогов и вопросно-ответными парами. На нем производилось сравнение изучаемых методов.
- Результаты данной работы **планируется расширить** некоторыми дополнительными экспериментами и **опубликовать** в журнале уровня Q1.



Этап 1: Литературный обзор

Инсайты литобзора

- На данный момент существует достаточное количество реализаций внешней памяти для LLM с использованием графов знаний ([GraphRAG](#), [AriGraph](#), [GraphReader](#), [HippoRAG](#)). Причем наиболее современные работы ориентируются на автоматическое построение и использование таких графов с помощью фреймворков на основе LLM
- Однако каждая работа предлагает уникальный дизайн системы и при этом имеет достойные результаты в своей области, что говорит о том, что графовые методы памяти имеют большой потенциал развития и могут синергировать друг с другом




Этап 2: Построение эталонного графа знаний полуавтоматически с ручным контролем

В работе был использован датасет DiaASQ, содержащий высказывания пользователей девайсов с крупного форума, а также извлеченные из них семантические конструкции. Используя данный датасет, мы подготовили единый граф знаний по всем высказываниям. Также, ввиду отсутствия в датасете вопросно-ответных пар, была произведена их процедурная генерация.

Модификация датасета:

- Сгенерированы имена спикеров, случайно встречающиеся в разных диалогах.
- Отфильтрованы некоторые конструкции, плохо вписывающиеся в граф.
- При помощи разметки высказываний (положительное / отрицательное / нейтральное) сгенерированы вопросно-ответные пары.
- Добавлена информация о производителях устройств



Пример полученного графа

Постановка задачи:

- Двенадцать наборов вопросов, примеры:
 - Сравнение характеристики двух девайсов (какой из девайсов лучше) - 170 вопросов
 - Оценка характеристики девайса (среднее мнение пользователей) - 58 вопросов
 - Мнение конкретного пользователя о конкретной характеристике девайса - 1253 вопроса
- Сравнение RAG vs Graph
- RAG тестируется в трех режимах:
 - Извлечение реплик
 - Извлечение диалогов
 - Смешанное извлечение
- Каждый из режимов тестируется с разным количеством извлекаемых объектов

```
{
  "question": "Which device is better in system: iQOO or 7pro?",
  "answer": "iQOO",
  "type": "compare_questions"
},
{
  "question": "Which device is better in signal: Xiaomi or Huawei?",
  "answer": "Huawei",
  "type": "compare_questions"
},
```

```
{
  "question": "The majority of speakers have positive, neutral or negative sentiment about charging of iQOO9 series?",
  "answer": "Positive",
  "type": "compare_sentiment"
},
{
  "question": "The majority of speakers have positive, neutral or negative sentiment about hand feel of k40 enhanced version?",
  "answer": "Positive",
  "type": "compare_sentiment"
},
```

```
{
  "question": "Joshua has positive, negative or neutral opinion about battery of Mi 9?",
  "answer": "Negative",
  "type": "simple"
},
{
  "question": "Laura has positive, negative or neutral opinion about price of AXON30ULTRA?",
  "answer": "Positive",
  "type": "simple"
},
```

Выводы

- По итогам 2 этапа мы аугментировали исходный датасет ([DiaASQ](#)), добавив в него:
 - Имена спикеров, даты диалогов.
 - Новые диалоги, содержащие изменения мнений некоторых спикеров.
 - Вопросы различных типов (поиск фактов, сравнение фактов, поиск цепочек фактов, анализ временных взаимосвязей, агрегация фактов).
- Также построили эталонный граф по аугментированному датасету, который в будущем будет использоваться для сравнения с RAG.



Этап 3: Разработка алгоритма извлечения данных из графа

QA по графу при помощи Cypher запроса:

1. Генерация с помощью LLM Cypher-запроса по вопросу.

Пример: Which devices have better battery: OPPO or Xiaomi?

```
MATCH (a)-[r]-(b) WHERE a.name="OPPO" AND b.name="battery" RETURN a.name as device,  
r.person as person, type(r) as opinion, b.name as feature
```

```
MATCH (a)-[r]-(b) WHERE a.name="Xiaomi" AND b.name="battery" RETURN a.name as device,  
r.person as person, type(r) as opinion, b.name as feature
```

1. Выполнение Cypher-запроса к СУБД neo4j, получение триплетов.

device: OPPO, person: Alise, opinion: good, feature: battery; device: OPPO, person: Brian, opinion: lasts long, feature: battery; device: Xiaomi, person: Christopher, opinion: weak, feature: battery, ...

1. Генерация с помощью LLM ответа по вопросу и триплетам, извлеченным из графа.

Answer: OPPO

QA по графу при помощи BFS:

1. Извлечение ключевых сущностей запроса с помощью LLM.

Пример: Which devices have better battery: OPPO or Xiaomi?


Entities: {"OPPO": "device", "Xiaomi": "device"}

1. Запуск BFS с выбранных стартовых вершин графа, получение триплетов.

device: OPPO, person: Alise, opinion: good, feature: battery;
device: OPPO, person: Jim, opinion: not so good, feature: signal;
device: OPPO, person: Brian, opinion: lasts long, feature: battery;
device: Xiaomi, person: Christopher, opinion: weak, feature: battery, ...

1. Генерация с помощью LLM ответа по вопросу и триплетам, извлеченным из графа.

Answer: OPPO



QA по графу при помощи A*:

1. Извлечение ключевых сущностей из запроса с помощью LLM.

Пример: Which devices have better battery: OPPO or Xiaomi?

Entities: battery, OPPO, Xiaomi

1. Запуск A* для каждой пары сущностей из запроса; использование близости эмбедингов вершин графа в качестве эвристической оценки расстояния [1]; получение уникальных триплетов.

device: OPPO, person: Alise, opinion: good, feature: battery; device: OPPO, person: Jim, opinion: not so good, feature: signal; device: OPPO, person: Brian, opinion: lasts long, feature: battery; device: Xiaomi, person: Christopher, opinion: weak, feature: battery, ...

1. Генерация с помощью LLM ответа на вопрос, используя триплеты, извлеченные из графа.

Answer: OPPO

Выводы

- Мы можем использовать двухэтапное извлечение: сначала пробовать генерировать `cypher query` к графу и исполнять его, в случае неудачи или извлечения достаточно большого числа триплетов - производить дополнительный поиск с помощью BFS или A*. Данная стратегия может быть имплементирована в рамках продолжения работ над проектом
- Данные алгоритмы доказали свою эффективность на собранном нами вопросно-ответном датасете, содержащим 12 типов вопросов, тестирующих обнаружение различных типов взаимосвязей в графе

Этап 4: Тестирование Q&A на эталонном графе

QA, accuracy

Тип вопроса	Пример вопроса	RAG	BFS	BFS + emb	A*	Cypher query
compare questions	Which device is better in battery life: Apple or k30u?	0.68	0.82	0.83	0.62	0.91
device sentiment	Kayla has positive, negative or neutral opinion about video of 10PRO on 25.11.2020?	0.5	0.53	0.50	0.38	0.81
compare sentiment	The majority of speakers have positive, neutral or negative sentiment about system of vivo?	0.6	0.63	0.55	0.42	0.81
same devices	Do Brianna and Joseph have any common devices (which Brianna and Joseph both use)? If so, list common devices. Otherwise, answer 'No'.	0.48	0.80	0.73	0.36	0.75
same manufacturers	Do Lily and Jenna prefer the same device manufacturer?	0.45	0.65	0.65	0.34	0.35
similar device opinions	Whose opinions from Anthony and Grace about devices are most similar to Faith's?	0.74	0.63	0.67	0.25	0.85
similar manuf opinions	Whose opinions from Evan and James about manufacturers are most similar to Abigail's?	0.83	0.83	0.67	0.08	0.5
which people about devices	Which people have negative opinion about video of 10PRO on 25.11.2020?	0.38	0.63	0.70	0.22	0.83

QA, accuracy

Тип вопроса	Пример вопроса	RAG	BFS	BFS + emb	A*	Cypher query
compare sentiment synonyms	The majority of speakers have positive, neutral or negative sentiment about <u>connection</u> of Apple?	0.59	0.53	0.60	0.16	-
which people about devices synonyms	Which people have positive opinion about <u>display</u> of Mi 10pro on 22.12.2018?	0.34	0.40	0.73	0.18	-
dominant opinion	What Jessica's opinion (positive, negative or neutral) about signal of Apple was dominant during using Apple?	0.59	0.60	0.70	0.58	0.55
last opinion	What opinion (positive, negative or neutral) about scheduling of IQOO9 was last during Zachary's experience of IQOO9?	0.68	0.70	0.80	0.52	0.60

Выводы

Предложенные алгоритмы извлечения из графа доказали свою состоятельность. BFS с использованием эмбедингов стабильно превзошел RAG на тестируемых вопросах, A* также обрабатывает корректно, но показывает более низкие значения метрик в силу того, что изначально проектировался под несколько другие задачи. В итоговом алгоритме извлечения используются оба варианта



Этап 5: Разработка построения и актуализации графа на слабоструктурированных данных

Типы связей в графе и их извлечение

- Обычные (связи между двумя узлами типа “объект” в графе)

Корабельщики в ответ: «Мы объехали
весь свет; За морем жительство не худо;
В свете ж вот какое чудо: Остров на
море лежит, Град на острове стоит
С златоглавыми церквами, С теремами
да садами;



[корабельщики, объехали весь,
свет], [жительство, не худо за, море],
[чудо, есть в, свет], [остров,
есть, чудо], [остров, лежит на,
море], [град, стоит на, остров],
[град, с, златоглавые церкви],
[град, с, сады], [град, с, терема]


- Тезисы (гиперсвязи между произвольным количеством узлов типа “объект”)

Корабельщики в ответ: «Мы объехали
весь свет; За морем жительство не худо;
В свете ж вот какое чудо: Остров на
море лежит, Град на острове стоит
С златоглавыми церквами, С теремами
да садами;




Корабельщики объехали весь свет:
[корабельщики, свет]
За морем жительство не худо: [море,
жительство, худо]
В свете чудо – остров лежит на
море: [свет, чудо, остров, море]
В свете чудо – град на острове
стоит: [свет, чудо, остров, град]...

Пример куска графа




Общая архитектура решения




Общая архитектура пайплайнов

ЗАПОМИНАНИЕ



ВСПОМИНАНИЕ



QA, accuracy

			Golden graph (LLaMA)			Golden graph (Gigachat)			Built graph gpt-4-mini (Gigachat)		Built graph Gigachat (Gigachat)	
№	RAG Llama	RAG Gigachat	BFS + emb	A star	Cypher query	BFS + emb	A star	Cypher query	BFS + emb	A star	BFS + emb	A star
1	0.68	0.66	0.94	0.63	0.82	0.88	0.56	0.48	0.73	0.32	0.78	0.25
2	0.5	0.48	0.54	0.55	0.42	0.50	0.46	0.48	0.63	0.34	0.70	0.25
3	0.6	0.38	0.66	0.47	0.62	0.60	0.25	0.44	0.48	0.26	0.47	0.24
4	0.48	0.52	0.85	0.50	0.90	0.81	0.28	0.86	0.54	0.43	0.48	0.48
5	0.74	0.58	0.81	0.03	0.97	0.74	0.38	0.55	0.67	0.35	0.47	0.38
6	0.38	0.37	0.64	0.61	0.72	0.79	0.15	0.62	0.30	0.03	0.37	0.02
7	0.59	0.41	0.60	0.37	-	0.26	0.21	-	0.36	0.23	0.27	0.17
8	0.34	0.28	0.54	0.32	-	0.82	0.08	-	0.16	0.01	0.33	0.01
9	0.59	0.59	0.68	0.48	0.64	0.62	0.37	0.54	0.58	0.38	0.59	0.37
10	0.68	0.65	0.74	0.66	0.72	0.74	0.46	0.68	0.70	-	0.60	0.40

Выводы

- На 5 этапе была разработана и имплементирована библиотека работы с графом, включающая инструменты его построения и извлечения знаний из него
- Данная библиотека была протестирована на диалоговом бенчмарке “DiaASQ”, полученные результаты показывают убедительное превосходство графовой памяти над RAG при использовании как LLaMA-3, так и Gigachat
- Было произведено пробное развертывание библиотеки в контуре Заказчика

По итогам 5 этапа мы сформулировали возможное улучшение графовой памяти, а именно - добавление лейблов к узлам и связям. В рамках 6-7 этапов, помимо прочего, были имплементированы шаблоны добавления в граф структурированных данных, а также смешанный ретривер, сочетающий преимущества BFS и A*.