

Зачем

Существующие модели памяти не позволяют AI-агентам точно понимать контекст, последовательность событий и учитывать актуальность информации.

Цель реализации исследования

Модель памяти для AI-агентов на основе графа знаний, которая позволит сохранять и находить необходимую информацию, представленную в виде текста на естественном языке

Key results

- Разработана новая версия QA пайплайна. Получен прирост на 15% по ExactMatch-метрике в сравнении с существующими GraphRAG-методами.
- Предложен алгоритм построения модели памяти на основе темпорального графа

Контекст:

Результаты исследования могут быть включены в повестку Research Magistral на 2026 год

Что

- Модель памяти для LLM-агента на основе графа знаний (Text-attributed Graph).
- Алгоритм поиска релевантной информации (с механизмом планирования) в предложенной модели памяти.
- Программная PersonalAI-библиотека с Memorize- и QA-пайплайнами.
- Научная новизна: комбинация графов знаний и мультиагентных LLM-based методов поиска информации для повышения качества генерации текстов на специализированную тематику.

Как (Initiatives)

- Обзор релевантных LLM-based GraphConstruction- и GraphRetrieval-методов.
- Генерация графа знаний по слабоструктурированным текстам на естественном языке с помощью LLM-модели.
- Использование механизма планирования для динамической корректировки поисковых запросов на основании извлекаемой промежуточной информации.
- Использование векторных представлений (как dense, так и sparse) поисковых запросов и хранимой информации в графе для оценки их семантической близости: релевантности хранимых текстов к user-вопросу для генерации правильного ответа.
- Использование алгоритмов обхода графа для извлечения релевантной информации.

Ресурсы


- Руководитель проекта - Евгений Бурнаев
- 5 ПШЕ
- Бюджет - 18,6 млн. руб.

Бенефициар

КИБ

Новый продукт/влияние на действующий

- Расширение возможностей “наставника клиентского менеджера” за счёт более эффективного способа хранения знаний
- Обогащение багажа знаний по эффективности различных моделей памяти для GigaChat-команды
- Перспективные приложения (AI-агенты) КИБ



Результаты работ

1. Выполнен обзор релевантных LLM-based (1) методов построения графов знаний и (2) алгоритмов поиска информации в графах для QA-задач.
1. Использована модель памяти для LLM-агента на основе графа знаний (Text-attributed Graph).
1. Реализован алгоритм (QA-пайплайн) поиска релевантной информации (для входящего user-вопроса) в предложенной модели памяти;
1. Разработанные алгоритмы интегрированы в программную PersonalAI-библиотеку с функционалом по: (1) добавлению информации в память и (2) поиску релевантной информации в памяти для QA-задач.
1. Выполнена оценка эффективности полученного решения.

1 Литературный обзор GraphConstruction- и GraphRetrieval-методов

GraphRetrieval-методы (Exact Match):

Датасет \ Метод	ToG (GPT4)	RoG (Llama2 7B)	PMKGE (GPT4)	GRAG (Llama2 7B)	GNN-RAG (Llama2 7B)	ToG2.0 (GPT3.5)	DoG (GPT4)	GCR (Llama3.1 8B + ChatGPT)	PDA (GPT3.5)
HotpotQA	41.0	43.0	42.6	36.1	43.0	40.9	45.3	45.9	36.5
WebQuestions	57.9	69.1	68.4	54.9	71.2	63.5	80.0	76.4	55.5

Можно выдвинуть следующие гипотезы:

- комбинация алгоритмов (1) унификации вершин/рёбер триплетов, (2) извлечения и унификации темпоральной информации, а также (3) поиска и фиксации устаревшей информации позволит повысить качество/стабильность построенного графа знаний.
- комбинация алгоритмов (1) итеративного поиска на основе обновляемого плана, (2) динамического сопоставления сущностей из вопроса с вершинами графа знаний, (3) модификации/корректировки исходного user-вопроса и (4) резюмирования/сжатия извлекаемой информации позволит получить прирост эффективности в рамках QA-задач (close domain).

2.1 Модель памяти для LLM-агента. Memorize-пайплайн.

Информация в памяти представлена в трёх форматах, отличающихся степенью гранулярности поддерживаемых/хранимых в них знаний:

- **Episodic** (исходные фрагменты текста для сохранения в память).
- **Thesis** (независимые полные краткие единицы знаний в виде текста на естественном языке).
- **Entities** (именованные сущности, объекты/субъекты реального мира).




Рисунок 1. Основные стадии Memorize-пайплайна по добавлению информации в модель памяти на основе графа знаний

2.2 Типы связей в графе и их извлечение

- Simple (связи между двумя вершинами типа object в графе)

Корабельщики в ответ: «Мы объехали
весь свет; За морем житье не худо; В
свете ж вот какое чудо: Остров на
море лежит, Град на острове стоит
С златоглавыми церквами, С теремами
да садами;



[корабельщики, объехали весь, свет],
[житье, не худо за, море], [чудо,
есть в, свет], [остров, есть, чудо],
[остров, лежит на, море], [град,
стоит на, остров], [град, с,
златоглавые церкви], [град, с,
сады], [град, с, терема]


- Hyper (связи между вершиной типа thesis и произвольным количеством вершин типа object)

Корабельщики в ответ: «Мы объехали
весь свет; За морем житье не худо; В
свете ж вот какое чудо: Остров на
море лежит, Град на острове стоит
С златоглавыми церквами, С теремами
да садами;



Корабельщики объехали весь свет:
[корабельщики, свет]
За морем житье не худо: [море,
житье, худо]
В свете чудо – остров лежит на море:
[свет, чудо, остров, море]
В свете чудо – град на острове
стоит: [свет, чудо, остров, град]...

2.3 Пример фрагмента построенного графа



3.1 Алгоритм поиска информации в модели памяти. QA-пайплайн.




Рисунок 2. Высокоуровневая схема QA-пайплайна по поиску релевантной информации в модели памяти на основе графа знаний

3.2 Доступный набор гиперпараметров QA-пайплайна

- Максимальное количество шагов плана поиска.
- Максимальное количество генерируемых Clue-вопросов в рамках одного шага плана поиска.
- Алгоритм обхода графа:
 - BeamSearch;
 - WaterCircles;
 - A*;
 - NaiveRetriever;
 - Mixture.
- Retrieve/Rerank-оператор:
 - SingleStep;
 - MultiStep;
 - EnsembleFusion.
- Версия промпта для заданной LLM-задачи. В рамках:
 - QueryPreprocessing-стадии 7 LLM-задач;
 - KGReasoning-стадии 2 и 9 задач для weak- и medium-версий соответственно;
 - AnswersAggregator-стадии 1 LLM-задача.
- Выбор операций предобработки user-вопроса в рамках QueryPreprocessing-стадии.
- Ограничения на типы извлекаемых триплетов: simple, hyper, episodic.

4 Personal AI библиотека

- Актуальная версия: v2.1.8
- Поддерживаемые DB-коннекторы:
 - KeyValue DB: Redis, Mongo, Mixed (Redis+Mongo), InMemory.
 - Table DB: Mongo, MySQL, PostgreSQL, SQLite3, InMemory.
 - Graph DB: Neo4j, Kuzu, InMemory, BlazeGraph.
 - Vector DB:
 - dense: Chroma, ElasticSearch, OpenSearch, InMemory (faiss), Weaviate, Qdrant.
 - bm25: ElasticSearch, OpenSearch, Weaviate, InMemory.
- Тестирование компонент системы:
 - интеграционных тестов к:
 - DB-коннекторам: 1296 / 79% cov;
 - модели памяти: 345 / 55% cov;
 - Retrieve/Rerank-операции: 792 / 75% cov;
 - механизмам кеширования: 64 / 72% cov.
 - функциональных тестов к:
 - Memorize-пайплайну: 4 / 63% cov;
 - QA-пайплайну: 524 / 62% cov;
 - PersonalAI-классу: 6 / 45% cov.
- Lines of code / Lines of comments: 15813 / 4107.

5 Количественные оценки эффективности полученного решения

В таблице представлены LLM-as-a-Judge оценки. В качестве Judge-модели использована Qwen2.5:7b.

Датасет / Модель	HotpotQA				RuBQ			
	weak pipeline		medium pipeline		weak pipeline		medium pipeline	
	best score	best config	best score	best config	best score	best config	best score	best config
GigaChat Max	0.74	naive_retriever (simple, hyper, episodic)	0.79	6 search steps, naive_retriever (simple, hyper, episodic)	0.83	naive_retriever (simple, hyper)	0.87	6 search steps, naive_retriever (simple, hyper, episodic)
DeepSeek V3	0.52	beamsearch+ watercircles (hyper, episodic)	0.64	9 search steps, beamsearch+ watercircles (hyper, episodic)	-			
Llama3.1 8B	0.59	beamsearch+ watercircles (hyper, episodic)	0.59	6 search steps, beamsearch+ watercircles (hyper, episodic)	-			

- Получен **прирост на 3%** (0.79; в качестве LLM задана GigaChat Max) по “**LLM-as-a-Judge**”-метрике в сравнении с предыдущей версией QA-пайплайна в рамках PersonalAI–библиотеки: 0.76 (в качестве LLM задана DeepSeek V3)
- Получен **прирост на 15%** по **ExactMatch**-метрике в сравнении с существующими GraphRAG-методами (указанных на слайде 3). Оценка по ExactMatch лучшей QA-конфигурации: 0.61 (полиномиальная интерполяция).

6.1 Дополнительно. Модель памяти LLM-агента на основе темпорального графа. Memorize-пайплайн.




Рисунок 3. Высокоуровневая схема Memorize-пайплайна по добавлению информации в модель памяти на основе темпорального графа знаний




Рисунок 4. Высокоуровневая схема пайплайна по поиску устаревшей информации в темпоральном графе

6.2 Дополнительно. Алгоритм поиска информации в темпоральном графе. QA-пайплайн.

В зависимости от входного user-вопроса используется комбинация следующих (четырёх) стратегий поиска информации в графе:

- **Snapshot QA** (конкретная временная метка T)
- **Timeline/Range** (интервал $[T_1, T_2]$)
- **Trend/Aggregation** (интервал $[T_1, T_2]$ с заданным шагом резюмирования)
- **Universal QA** (конкретная метка T /интервал $[T_1, T_2]$ /отсутствие временной составляющей)




Рисунок 5. Основные стадии у стратегий поиска информации (в рамках QA-пайплайна) в темпоральном графе. Ключевые этапы (которые меняются в зависимости от стратегии поиска) выделены зеленым цветом.

7 Направления развития предложенного решения

1. Валидация/унификация хранимых объектов/отношений в памяти (Nodes/Relations Resolution).
1. Поддержка диалогового взаимодействия с моделью памяти в рамках QA-пайплайна.
1. Добавление отдельных компонент по разбору/извлечению информации из входных текстовых данных в специализированном формате (перед сохранением в память).
1. Расширение списка механизмов/техник по контролю эффективности и производительности, а также обеспечению надёжности и безопасности полученного LLM-based решения.
1. Оптимизация Reasoning/Acting/Observing-цепочек (workflows) с LLM-based звеньями: поиск/выделение шаблонов, сведение reasoning-операций к решению задач классификации.
1. Расширение функционала LLM-агента: доступ к внешним/поддерживаемым “инструментам”.
1. Расширение списка поддерживаемых модальностей данных.

Зачем

Существующие модели памяти не позволяют AI-агентам точно понимать контекст, последовательность событий и учитывать актуальность информации.

Цель реализации исследования

Модель памяти для AI-агентов на основе графа знаний, которая позволит сохранять и находить необходимую информацию, представленную в виде текста на естественном языке

Key results

- Разработана новая версия QA пайплайна. Получен прирост на 15% по ExactMatch-метрике в сравнении с существующими GraphRAG-методами.
- Предложен алгоритм построения модели памяти на основе темпорального графа

Контекст:

Результаты исследования могут быть включены в повестку Research Magistral на 2026 год

Что

- Модель памяти для LLM-агента на основе графа знаний (Text-attributed Graph).
- Алгоритм поиска релевантной информации (с механизмом планирования) в предложенной модели памяти.
- Программная PersonalAI-библиотека с Memorize- и QA-пайплайнами.
- Научная новизна: комбинация графов знаний и мультиагентных LLM-based методов поиска информации для повышения качества генерации текстов на специализированную тематику.

Как (Initiatives)

- Обзор релевантных LLM-based GraphConstruction- и GraphRetrieval-методов.
- Генерация графа знаний по слабоструктурированным текстам на естественном языке с помощью LLM-моделей.
- Использование механизма планирования для динамической корректировки поисковых запросов на основании извлекаемой промежуточной информации.
- Использование векторных представлений (как dense, так и sparse) поисковых запросов и хранимой информации в графе для оценки их семантической близости: релевантности хранимых текстов к user-вопросу для генерации правильного ответа.
- Использование алгоритмов обхода графа для извлечения релевантной информации.

Ресурсы


- Руководитель проекта - Евгений Бурнаев
- 5 ПШЕ
- Бюджет - 18,6 млн. руб.

Бенефициар

КИБ

Новый продукт/влияние на действующий

- Расширение возможностей “наставника клиентского менеджера” за счёт более эффективного способа хранения знаний
- Обогащение багажа знаний по эффективности различных моделей памяти для GigaChat-команды
- Перспективные приложения (AI-агенты) КИБ





Цель реализации исследования

Разработать новую архитектуру памяти для AI-агентов (граф знаний + временные связи) и продемонстрировать её преимущества в задачах Q&A и навигации по информации

Key results

- Разработана новая версия Q&A пайплайна с графовым поиском (ускорение и повышение полноты)
- Создан модуль временной памяти — позволяет агентам учитывать последовательность и давность событий (сверх T3)
- Архитектура готова к интеграции в PersonalAI и GigaChat для расширения контекста и повышения качества ответов.

Контекст:

Современные LLM не умеют надёжно хранить долгосрочный контекст. Компании по всему миру инвестируют в memory-systems; графовая память — один из ключевых претендентов на стандарт будущих AI-агентов

Что

- Разработана архитектура графовой памяти для AI-агентов, позволяющая сохранять факты как связанные структуры знаний
- Реализован прототип Q&A пайплайна с быстрым графовым поиском
- Дополнительно создан механизм учёта временных меток для рассуждений о последовательности событий

Как (Initiatives)

- Спроектирована когнитивная модель памяти на графах знаний
- Построены пайплайны извлечения и пополнения памяти
- Реализован прототип высокопроизводительного поиска контекста
- Добавлен модуль работы с временными данными

Зачем

Обеспечить LLM-агентов памятью, которая понимает связи, историю и актуальность фактов — это ключ к созданию надёжных персональных и корпоративных AI-ассистентов

Ресурсы

- Руководитель: Евгений Бурнаев
- 5 ПШЕ
- Бюджет - 18,6 млн. руб.

Бенефициар

КИБ

Новый продукт/влияние на действующий

- Расширение возможностей наставника клиентского менеджера за счёт долговременной памяти
- Повышение персонализации и качества диалога в GigaChat
- База для создания “умных” AI-агентов, которые помнят, учатся и адаптируются

2024

Q3 2025

Q4 2025

Библиотека PersonalAI для построения графа

Разработка Q&A пайплайна

Внедрение QA- пайплайна

Планы по дальнейшей реализации